

PROPOSAL PROYEK AKHIR

SKETCHBOOK UNIVERSE: KLASIFIKASI SKETSA BERBASIS CNN
MOBILENET DAN ANALISIS POLA PERILAKU SISWA SMP DENGAN
K-MEANS CLUSTERING

SKETCHBOOK UNIVERSE: SKETCH CLASSIFICATION BASED ON
CNN MOBILENET AND BEHAVIORAL PATTERN ANALYSIS OF
JUNIOR HIGH SCHOOL STUDENTS USING K-MEANS CLUSTERING

Diajukan Untuk Memenuhi Salah Satu Syarat Memperoleh Gelar Sarjana
Teknik

pada Program Studi D4 Teknologi Rekayasa Multimedia

Politeknik Elektronika Negeri Surabaya

Muhammad Dias Al Izzat

NRP: 5322600012

Dosen Pembimbing:

[Nama Dosen Pembimbing]

POLITEKNIK ELEKTRONIKA NERI SURABAYA

TAHUN 2026

HALAMAN PENGESAHAN

PROPOSAL PROYEK AKHIR

SKETCHBOOK UNIVERSE: KLASIFIKASI SKETSA BERBASIS CNN MOBILENET DAN ANALISIS POLA PERILAKU SISWA SMP DENGAN K-MEANS CLUSTERING

Diajukan oleh:

- Nama: Muhammad Dias Al Izzat
- NRP: 5322600012
- Program Studi: D4 Teknologi Rekayasa Multimedia

Telah disetujui dan disahkan sebagai Proposal Proyek Akhir di Politeknik Elektronika Negeri Surabaya pada tanggal _____.

Surabaya, _____

Dosen Pembimbing,

[Nama Dosen Pembimbing]

ABSTRAK

SKETCHBOOK UNIVERSE: KLASIFIKASI SKETSA BERBASIS CNN MOBILENET DAN ANALISIS POLA PERILAKU SISWA SMP DENGAN K-MEANS CLUSTERING

Nama: Muhammad Dias Al Izzat NRP: 5322600012

Kecerdasan buatan (AI) telah menjadi bagian tak terpisahkan dari kehidupan sehari-hari, termasuk bagi siswa Sekolah Menengah Pertama (SMP). Namun, paparan terhadap AI tanpa scaffolding yang tepat berisiko menimbulkan automation bias. Penelitian ini mengusulkan Sketchbook Universe, sebuah simulasi interaktif berbasis Human-in-the-Loop (HITL) untuk memfasilitasi interaksi reflektif siswa SMP terhadap output AI. Bagian backend sistem ini mencakup klasifikasi sketsa menggunakan Convolutional Neural Network (CNN) MobileNet yang dideploy secara client-side melalui TensorFlow.js, REST API berbasis Node.js dan Express untuk data logging ke SQLite, serta analisis pola perilaku siswa menggunakan K-Means clustering. Sistem menghasilkan tiga hingga lima cluster perilaku (Trust Acceptor, Critical Evaluator, Uncertain Explorer) yang dapat dimanfaatkan oleh guru untuk evaluasi pembelajaran. Penelitian ini menggunakan metode Mixed Methods dengan pendekatan Research and Development (R&D), metode pengembangan SDLC Waterfall, dan teknik analisis Fishbone 6M. Pengujian dilakukan menggunakan akurasi model CNN dan System Usability Scale (SUS) bersama rekan penelitian. Scope penelitian mencakup backend, CNN, K-Means, REST API, dan admin dash-

board, sementara frontend, UI/UX, dan maskot ditangani oleh rekan penelitian sebagai proyek kelompok.

Kata Kunci: Klasifikasi Sketsa, CNN MobileNet, TensorFlow.js, K-Means Clustering, Human-in-the-Loop, Data Logging

ABSTRACT

SKETCHBOOK UNIVERSE: SKETCH CLASSIFICATION BASED ON CNN MOBILENET AND BEHAVIORAL PATTERN ANALYSIS OF JUNIOR HIGH SCHOOL STUDENTS USING K-MEANS CLUSTERING

Name: Muhammad Dias Al Izzat NRP: 5322600012

Artificial Intelligence (AI) has become an inseparable part of daily life, including for junior high school students. However, exposure to AI without proper scaffolding risks automation bias. This research proposes Sketchbook Universe, an interactive simulation based on Human-in-the-Loop (HITL) to facilitate reflective interaction of junior high school students with AI output. The backend part of this system includes sketch classification using Convolutional Neural Network (CNN) MobileNet deployed client-side via TensorFlow.js, REST API based on Node.js and Express for data logging to SQLite, and student behavioral pattern analysis using K-Means clustering. The system produces three to five behavioral clusters (Trust Acceptor, Critical Evaluator, Uncertain Explorer) that can be utilized by teachers for learning evaluation. The research uses Mixed Methods with Research and Development (R&D) approach, SDLC Waterfall development method, and Fishbone 6M analysis technique. Testing is conducted using CNN model accuracy and System Usability Scale (SUS) together with the research partner. The research scope covers backend, CNN, K-Means, REST API, and admin dashboard, while frontend, UI/UX, and mascot are handled by the research partner as a group project.

Keywords: Sketch Classification, CNN MobileNet, TensorFlow.js, K-Means Clustering, Human-in-the-Loop, Data Logging

CONTENTS

HALAMAN PENGESAHAN	1
ABSTRAK	2
ABSTRACT	4
DAFTAR GAMBAR	10
DAFTAR TABEL	11
1 PENDAHULUAN	12
1.1 LATAR BELAKANG	12
1.2 PERMASALAHAN	14
1.3 BATASAN MASALAH	14
1.4 TUJUAN	15
1.5 MANFAAT	15
1.6 SISTEMATIKA PENULISAN	16
2 KAJIAN PUSTAKA	17
2.1 DESKRIPSI PERMASALAHAN	17
2.2 TEORI PENUNJANG	19
2.2.1 Literasi Kecerdasan Buatan	19
2.2.2 Human-in-the-Loop pada Sistem Klasifikasi	20
2.2.3 Klasifikasi Sketsa	21
2.2.4 Convolutional Neural Network dan MobileNet	22

2.2.5	TensorFlow.js dan Client-Side Inference	23
2.2.6	Confidence Score dan Data Logging	24
2.2.7	K-Means Clustering	25
2.3	PENELITIAN TERKAIT	26
2.3.1	Deep Learning for Free-Hand Sketch Recognition . . .	26
2.3.2	Front-End Deep Learning Web Applications	27
2.3.3	Confidence Visualization	27
2.3.4	K-Means untuk Pola Belajar	28
2.3.5	State of The Art	29
3	DESKRIPSI SISTEM	31
3.1	DESKRIPSI SOLUSI	31
3.2	METODOLOGI PENELITIAN	33
3.2.1	Pendekatan dan Jenis Penelitian	33
3.2.2	Metode Pengembangan (Waterfall SDLC)	34
3.2.3	Analisis Masalah (Fishbone 6M)	36
3.2.4	Teknik Pengumpulan Data	40
3.2.5	Teknik Analisis Data	40
3.2.6	Metode Pengujian	41
3.3	DESAIN SISTEM	42
3.3.1	Perancangan Sistem Global	42
3.3.2	Perancangan Arsitektur Sistem Hybrid	44
3.3.3	Perancangan Model CNN MobileNet	45
3.3.4	Perancangan Use Case	48
3.3.5	Perancangan Data Log Schema	50
3.3.6	Perancangan Backend API	52
3.3.7	Perancangan K-Means Clustering	54
3.3.8	Perancangan Admin Dashboard	57
3.3.9	Perancangan Sequence Diagram	59
3.3.10	Perancangan Klasifikasi Objek (Solid / Danger)	60

3.3.11 Perancangan Technology Stack	61
3.3.12 Perancangan Kontrak Data Dias–Can	63
3.4 PEMBAGIAN TUGAS DAN ALUR Pengerjaan	64
3.5 JADWAL PENELITIAN	66
DAFTAR PUSTAKA	69

LIST OF FIGURES

3.1	Gambar 3.1 Metode Pengembangan Waterfall SDLC untuk Sketchbook Universe	35
3.2	Fishbone Diagram 6M untuk Analisis Root Cause Automation Bias pada Siswa SMP	39
3.3	Gambar 3.3 Desain Sistem Global Input Process Output 4 Layer Sketchbook Universe	44
3.4	Gambar 3.4 Arsitektur Sistem Hybrid Browser-Based Inference dan Server-Side Services	45
3.5	Gambar 3.5 Arsitektur CNN MobileNet V2 dari Training ke Konversi TensorFlow.js	48
3.6	Gambar 3.6 Backend Logging Flow dan Top-6 Check Flow	54
3.7	Gambar 3.7 Pipeline K-Means Clustering dari Data Log ke Segmentasi Tipe Pengambil Keputusan Siswa	57
3.8	Gambar 3.8 Wireframe Guru Dashboard Session List Decision Metrics Clustering Result Export Data	59
3.9	Gambar 3.9 Wireframe Superadmin Dashboard Schools Overview Create School Create Class Generate Nomor Absen Create Guru Assign Guru Post-Pivot 16 Juni 2026	59
3.10	Gambar 3.10 Sequence Diagram Login Flow Siswa Frontend Backend Database	60
3.11	Gambar 3.11 Sequence Diagram Override dan Top-6 Check Flow Siswa Frontend CNN Backend Database	60

3.12	Gambar 3.12 Sequence Diagram Data Logging Flow Frontend	
	Backend Database K-Means Worker Offline Batch	60

LIST OF TABLES

2.1	Rangkuman Cakupan Penelitian Terkait	29
3.1	Analisis Masalah Automation Bias — Fishbone 6M (Perspektif Scope Dias)	37
3.2	Hyperparameter CNN MobileNet V2 — Initial Value	47
3.3	Use Case yang Menjadi Tanggung Jawab Scope Dias	49
3.4	Struktur JSON Interaction Log (Post-Pivot 16/6/26)	51
3.5	Daftar Endpoint REST API (Post-Pivot 16/6/26)	53
3.6	Feature Engineering untuk K-Means Clustering (per Siswa)	55
3.7	Contoh Pemetaan Label ke Behavior (Post-Pivot Decorative Dihapus)	61
3.8	Technology Stack Scope Dias	62
3.9	Kontrak Data Dias–Can (Ringkas)	64
3.10	Pembagian Tugas Can dan Dias per Komponen Sistem	65
3.11	Jadwal Penelitian Sinkron Can dan Dias — 17 Kegiatan × 12 Bulan	67

BAB 1

PENDAHULUAN

1.1 LATAR BELAKANG

Perkembangan kecerdasan buatan telah mendorong kebutuhan literasi teknologi yang tidak hanya menekankan kemampuan menggunakan aplikasi digital, tetapi juga kemampuan memahami cara kerja sistem cerdas. Sistem kecerdasan buatan banyak bekerja melalui proses prediksi, sehingga keluaran yang diberikan tidak selalu dapat dipahami sebagai jawaban mutlak. Pada konteks pendidikan, pemahaman tersebut penting agar siswa dapat membaca hasil sistem secara lebih kritis.

Literasi kecerdasan buatan mencakup kemampuan memahami, menggunakan, mengevaluasi, dan mempertimbangkan dampak penggunaan sistem berbasis kecerdasan buatan [1]. Pada konteks K-12, pembelajaran kecerdasan buatan membutuhkan pendekatan yang dapat menghubungkan konsep teknis dengan pengalaman belajar yang konkret [2]. Salah satu cara untuk memperlihatkan cara kerja sistem kecerdasan buatan adalah melalui aktivitas klasifikasi sketsa, karena siswa dapat melihat hubungan antara input gambar, prediksi sistem, dan nilai keyakinan model.

Sistem literasi kecerdasan buatan yang dikembangkan dalam proyek ini menggunakan proses klasifikasi sketsa. Siswa menggambar objek, kemudian sistem melakukan klasifikasi terhadap gambar tersebut. Hasil klasifikasi ditampilkan dalam bentuk Top-3 prediction dan confidence score. Confidence score digunakan untuk menunjukkan tingkat keyakinan model terhadap hasil

prediksi. Penyajian ini penting karena siswa dapat melihat bahwa prediksi sistem memiliki tingkat keyakinan yang berbeda-beda.

Explainable Artificial Intelligence dalam pendidikan menekankan pentingnya penyajian keluaran sistem agar dapat dipahami oleh pengguna [3]. Dalam penelitian ini, explainability diwujudkan melalui tampilan Top-3 prediction dan confidence score yang kemudian digunakan pada mekanisme Human-in-the-Loop. Siswa dapat menerima prediksi utama, memilih prediksi alternatif, atau melakukan override terhadap hasil sistem. Dengan demikian, model klasifikasi tidak hanya menjadi komponen teknis, tetapi juga menjadi bagian dari pengalaman belajar evaluatif.

Dari sisi teknis, sistem menggunakan model Convolutional Neural Network berbasis MobileNet untuk klasifikasi sketsa. CNN dipilih karena memiliki kemampuan mengekstraksi pola visual pada citra, sedangkan MobileNet dipilih karena lebih ringan untuk kebutuhan inferensi pada perangkat pengguna. Kajian mengenai deep learning untuk free-hand sketch menunjukkan bahwa sketsa memiliki karakteristik visual yang berbeda dari citra fotografis, sehingga preprocessing dan pemilihan arsitektur model perlu diperhatikan [6].

Model yang dikembangkan direncanakan berjalan pada sisi klien menggunakan TensorFlow.js. Pendekatan client-side inference dipilih agar proses klasifikasi dapat dilakukan di browser tanpa server kecerdasan buatan. Server hanya digunakan untuk REST API logging dan penyimpanan data interaksi. Kajian mengenai front-end deep learning menunjukkan bahwa deployment model pada aplikasi web memiliki peluang untuk membuat inferensi lebih dekat dengan pengguna, tetapi tetap membutuhkan perhatian pada ukuran model, latency, dan kompatibilitas browser [7].

Selain klasifikasi, penelitian ini juga mencatat data interaksi pengguna. Data yang dicatat meliputi hasil prediksi, confidence score, confidence gap, keputusan pengguna, durasi pengambilan keputusan, kategori objek, retry count, dan status level. Data tersebut kemudian digunakan untuk menganalisis pola keputusan pengguna menggunakan K-Means clustering. Analisis ini

tidak digunakan untuk menyimpulkan peningkatan kemampuan siswa melalui pre-test dan post-test, tetapi untuk membaca kecenderungan perilaku pengguna terhadap keluaran probabilistik sistem.

Berdasarkan kebutuhan tersebut, penelitian ini berfokus pada pengembangan sistem klasifikasi sketsa berbasis CNN MobileNet dengan confidence score dan clustering pola keputusan pada sistem literasi kecerdasan buatan untuk siswa SMP. Fokus utama penelitian berada pada pipeline preprocessing, model klasifikasi, konversi TensorFlow.js, pencatatan log, struktur database, dan analisis pola keputusan menggunakan K-Means clustering.

1.2 PERMASALAHAN

Sistem literasi kecerdasan buatan membutuhkan model klasifikasi yang mampu mengenali sketsa siswa dan menyajikan keluaran dalam bentuk yang dapat dievaluasi. Apabila sistem hanya menampilkan satu label akhir, pengguna berpotensi memahami hasil model sebagai jawaban mutlak. Oleh karena itu, diperlukan sistem klasifikasi sketsa berbasis CNN MobileNet yang dapat menghasilkan Top-3 prediction dan confidence score, menjalankan inferensi pada sisi klien menggunakan TensorFlow.js, serta mencatat log keputusan pengguna untuk dianalisis sebagai pola perilaku terhadap keluaran probabilistik sistem.

1.3 BATASAN MASALAH

1. Penelitian ini dibatasi pada pengembangan model klasifikasi sketsa berbasis CNN MobileNet untuk mendukung sistem literasi kecerdasan buatan bagi siswa SMP kelas 7 sampai 9.
2. Model dijalankan menggunakan TensorFlow.js pada sisi klien, sehingga tidak menggunakan backend kecerdasan buatan, server machine learning, atau inferensi berbasis cloud.

3. Dataset yang digunakan dibatasi pada subset kategori sketsa yang relevan dengan kebutuhan simulasi, yaitu kategori yang dapat dipetakan menjadi Solid, Danger, atau Decorative.
4. Sistem tidak melakukan pelatihan ulang model secara otomatis dari input pengguna dan tidak bersifat adaptif terhadap keputusan pengguna secara real-time.
5. Server hanya digunakan untuk REST API logging dan penyimpanan data interaksi menggunakan SQLite.
6. Analisis K-Means clustering difokuskan pada pola keputusan pengguna berdasarkan log interaksi dan tidak digunakan untuk menyimpulkan peningkatan kemampuan siswa melalui pre-test dan post-test.

1.4 TUJUAN

Penelitian ini bertujuan untuk mengembangkan sistem klasifikasi sketsa berbasis CNN MobileNet yang dapat mendukung sistem literasi kecerdasan buatan siswa SMP. Tujuan khusus penelitian ini adalah menghasilkan keluaran klasifikasi berupa Top-3 prediction dan confidence score yang dapat digunakan pada mekanisme Human-in-the-Loop. Penelitian ini juga bertujuan merancang pipeline client-side inference menggunakan TensorFlow.js, sistem logging berbasis REST API dan SQLite, serta analisis pola keputusan menggunakan K-Means clustering.

1.5 MANFAAT

1. Bagi siswa, sistem ini dapat membantu memperlihatkan bahwa hasil kecerdasan buatan bersifat prediktif dan memiliki tingkat keyakinan tertentu.
2. Bagi guru atau sekolah, sistem ini dapat menjadi media pendukung pembelajaran literasi kecerdasan buatan berbasis aktivitas interaktif.

3. Bagi pengembang sistem, penelitian ini memberikan rancangan pipeline klasifikasi sketsa client-side yang dapat diintegrasikan dengan simulasi web.
4. Bagi peneliti, data log dan hasil clustering dapat menjadi dasar analisis pola keputusan pengguna terhadap keluaran probabilistik sistem.

1.6 SISTEMATIKA PENULISAN

BAB I Pendahuluan: membahas latar belakang, permasalahan, batasan masalah, tujuan, manfaat, dan sistematika penulisan. BAB II Kajian Pustaka: membahas deskripsi permasalahan, teori penunjang, penelitian terkait, dan state of the art. BAB III Deskripsi Sistem: membahas deskripsi solusi, metodologi penelitian, desain sistem, rancangan pengujian, dan jadwal penelitian.

BAB 2

KAJIAN PUSTAKA

Bab ini menyajikan kajian pustaka yang menjadi landasan teoretis bagi perancangan komponen backend, klasifikasi, pencatatan data, dan analisis pada sistem Sketchbook Universe. Kajian dimulai dari deskripsi permasalahan yang menjelaskan mengapa klasifikasi berlabel tunggal belum memadai secara pedagogis, mengapa confidence score harus divisualisasikan, dan mengapa pencatatan interaksi harus terstruktur untuk keperluan analisis. Dilanjutkan dengan teori penunjang yang mendasari setiap keputusan teknis—mulai dari literasi kecerdasan buatan, Human-in-the-Loop, klasifikasi sketsa, arsitektur CNN dan MobileNet, inferensi client-side dengan TensorFlow.js, confidence score, data logging, hingga K-Means clustering—serta ditutup dengan penelitian terkait dan analisis state of the art yang memosisikan kontribusi teknis proyek ini di antara kajian-kajian sebelumnya. Pembahasan teori pada bab ini bersifat ringkas; rincian implementasi teknis akan diuraikan pada Bab III.

2.1 DESKRIPSI PERMASALAHAN

Permasalahan utama yang menjadi landasan proyek ini adalah belum adanya media interaktif yang memfasilitasi siswa SMP kelas 7–9 untuk mengevaluasi keluaran kecerdasan buatan secara reflektif melalui simulasi klasifikasi sketsa. Sebagian besar aplikasi klasifikasi gambar yang tersedia saat ini menampilkan satu label prediksi sebagai keluaran final, tanpa menunjukkan distribusi probabilitas di balik keputusan tersebut. Pendekatan klasifikasi berlabel tung-

gal ini secara pedagogis tidak memadai karena menyembunyikan ketidakpastian inheren dari model—siswa tidak mendapat kesempatan untuk mengamati bahwa AI seringkali tidak “yakin” dengan satu jawaban, melainkan mendistribusikan probabilitas ke beberapa kelas sekaligus [1]. Tanpa visibilitas terhadap distribusi probabilitas tersebut, siswa cenderung menerima keluaran AI secara wholesale, yang merupakan manifestasi dari fenomena automation bias—kecenderungan manusia untuk mempercayai keluaran sistem otomatis tanpa evaluasi kritis [4].

Persoalan ini diperkuat oleh temuan dalam literatur Explainable AI (XAI) di konteks pendidikan. Khosravi et al. [3] menekankan bahwa transparansi proses keputusan AI merupakan prasyarat bagi peserta didik untuk dapat menginterrogasi dan mengevaluasi keluaran tersebut. Dalam konteks klasifikasi sketsa, transparansi ini dapat diwujudkan melalui visualisasi confidence score pada Top-3 prediction, sehingga siswa dapat melihat bukan hanya apa yang “dipilih” oleh AI, tetapi juga seberapa yakin AI terhadap pilihannya dan alternatif-alternatif apa yang dipertimbangkan. Selain permasalahan visibilitas keluaran, terdapat pula tantangan dalam hal pencatatan interaksi siswa. Agar pola keputusan siswa terhadap keluaran AI dapat dianalisis secara sistematis, diperlukan mekanisme data logging yang terstruktur—bukan sekadar mencatat hasil akhir, melainkan menangkap konteks lengkap setiap keputusan: sketsa yang diklasifikasikan, distribusi confidence score, keputusan yang diambil siswa, serta waktu respons [5] [10].

Dengan demikian, permasalahan ini memiliki tiga dimensi yang saling terkait: (1) kebutuhan akan klasifikasi multi-label dengan visibilitas confidence untuk memerangi automation bias; (2) kebutuhan akan logging terstruktur sebagai fondasi analisis perilaku keputusan; serta (3) kebutuhan akan metode analisis yang mampu mengelompokkan pola keputusan siswa secara interpretif. Proyek Sketchbook Universe merespons ketiga dimensi ini melalui integrasi klasifikasi sketsa berbasis MobileNet dengan visualisasi Top-3 confidence, mekanisme Human-in-the-Loop yang mencatat keputusan siswa, serta

analisis K-Means clustering pada data log untuk mengidentifikasi pola keputusan.

2.2 TEORI PENUNJANG

Bagian ini membahas teori-teori yang mendasari perancangan komponen teknis pada proyek Sketchbook Universe. Pembahasan bersifat ringkas; rincian implementasi teknis akan diuraikan pada Bab III.

2.2.1 Literasi Kecerdasan Buatan

Literasi kecerdasan buatan didefinisikan oleh Ng et al. [1] sebagai seperangkat kompetensi yang memungkinkan individu untuk memahami, menggunakan, mengevaluasi, dan merefleksikan teknologi AI dalam konteks kehidupan sehari-hari. Kerangka konseptual tersebut mencakup empat dimensi utama: know and understand AI, use and apply AI, evaluate and create AI, serta AI ethics. Dimensi evaluasi menjadi sangat relevan dalam konteks proyek ini karena mencakup kemampuan untuk menilai keluaran AI secara kritis—termasuk memahami bahwa keluaran AI bersifat probabilistik, bukan deterministik. Ng et al. secara eksplisit menekankan bahwa penalaran probabilistik merupakan komponen fundamental literasi AI: individu yang melek AI harus mampu mengevaluasi keluaran probabilistik dari model, memahami bahwa confidence score merepresentasikan tingkat keyakinan model—bukan kebenaran absolut—dan mempertimbangkan alternatif-alternatif yang mungkin sama masuk akalanya [1].

Dalam konteks K-12, Casal-Otero et al. [2] melakukan tinjauan sistematis terhadap implementasi literasi AI di jenjang pendidikan dasar dan menengah. Mereka menemukan bahwa strategi literasi AI yang efektif untuk siswa usia sekolah harus mempertimbangkan tahap perkembangan kognitif peserta didik—siswa SMP belum sepenuhnya mampu berpikir abstrak tentang konsep probabilistik, sehingga diperlukan strategi yang sesuai usia (age-appropriate

strategies) untuk membuat konsep tersebut teramati dan bermakna. Koneksi antara teori literasi AI dan proyek ini terletak pada mekanisme klasifikasi sketsa dengan visualisasi Top-3 confidence score: ketika model MobileNet mengklasifikasikan sketsa siswa dan menampilkan tiga prediksi teratas beserta nilai confidence-nya, siswa dapat secara langsung mengamati bahwa AI mendistribusikan keyakinannya ke beberapa kelas—bukan hanya menunjuk satu jawaban dengan kepastian penuh.

2.2.2 Human-in-the-Loop pada Sistem Klasifikasi

Konsep Human-in-the-Loop (HITL) merujuk pada paradigma di mana manusia berpartisipasi secara aktif dalam alur keputusan sistem otomatis, baik dengan memberikan masukan, mengoreksi keluaran, maupun membuat keputusan final [4]. Mosqueira-Rey et al. [4] mengidentifikasi bahwa HITL menjadi penting terutama ketika keluaran sistem otomatis memiliki konsekuensi signifikan dan ketika terdapat risiko automation bias—yaitu kecenderungan manusia untuk menerima keluaran sistem otomatis secara tidak kritis karena asumsi bahwa mesin “lebih tahu”. Dalam konteks klasifikasi, automation bias terjadi ketika pengguna menerima label prediksi AI tanpa mempertimbangkan kemungkinan kesalahan atau alternatif lain, yang justru menghilangkan kesempatan untuk evaluasi kritis. Khosravi et al. [3] menambahkan dimensi XAI ke dalam diskusi HITL dengan menekankan bahwa transparansi proses keputusan AI merupakan prasyarat bagi pengguna untuk dapat melakukan evaluasi yang bermakna.

Memarian & Doleck [5] melakukan analisis khusus terhadap peran HITL dalam domain Artificial Intelligence in Education (AIED). Mereka menemukan bahwa dalam sistem AIED, peran manusia dapat dikategorikan menjadi beberapa tipe: sebagai supervisor yang mengawasi keputusan sistem, sebagai corrector yang memperbaiki keluaran yang salah, dan sebagai decision-maker yang membuat keputusan final berdasarkan informasi dari sistem. Temuan penting adalah bahwa efektivitas HITL bergantung pada kualitas informasi

yang diberikan kepada manusia—jika sistem hanya menampilkan keluaran final tanpa konteks, manusia cenderung menjadi rubber stamp yang sekadar menyetujui keputusan mesin. Dalam proyek Sketchbook Universe, implementasi HITL dirancang dengan prinsip yang jelas: sistem menyediakan informasi klasifikasi (Top-3 confidence score) kepada siswa, kemudian siswa membuat keputusan apakah setuju atau menolak prediksi AI. Keputusan siswa dicatat sebagai log untuk keperluan analisis, namun tidak digunakan untuk melatih ulang model—model MobileNet bersifat statis, sementara keputusan siswa dicatat murni sebagai data observasi untuk analisis pola perilaku.

2.2.3 Klasifikasi Sketsa

Klasifikasi sketsa (sketch classification) merupakan tugas mengkategorikan gambar sketsa tangan ke dalam kelas-kelas yang telah ditentukan. Meskipun secara konseptual serupa dengan klasifikasi gambar fotografis, klasifikasi sketsa memiliki karakteristik tersendiri yang menjadikannya lebih menantang. Xu et al. [6] dalam survei komprehensif mereka mengenai deep learning untuk sketsa tangan bebas mengidentifikasi beberapa perbedaan fundamental antara sketsa dan foto: (1) sketsa bersifat sparse—hanya berisi garis-garis esensial tanpa informasi warna atau tekstur; (2) sketsa memiliki tingkat abstraksi yang bervariasi—dua orang dapat menggambar objek yang sama dengan level detail yang sangat berbeda; dan (3) sketsa seringkali ambigu—sebuah sketsa yang dimaksudkan sebagai “bintang” dapat menyerupai “roda” atau “matahari” tergantung pada interpretasi penggambar.

Tantangan klasifikasi sketsa semakin kompleks dalam konteks siswa SMP karena variasi gaya menggambar yang dipengaruhi oleh faktor usia dan kemampuan motorik. Variasi ini menyebabkan distribusi confidence score pada model klasifikasi menjadi lebih menyebar—model seringkali tidak dapat memberikan prediksi dengan confidence tinggi pada satu kelas saja, melainkan mendistribusikan probabilitas ke beberapa kelas sekaligus. Kondisi ini justru menguntungkan secara pedagogis, karena siswa dapat melihat bahwa AI tidak

selalu “yakin” dan perlu mengevaluasi alternatif-alternatif yang ditampilkan. Dalam proyek ini, klasifikasi sketsa tidak hanya berfungsi sebagai tugas pengenalan pola, tetapi juga sebagai sarana untuk memperlihatkan proses evaluasi terhadap keluaran AI. Kategori sketsa yang digunakan dalam sistem ini terbagi menjadi tiga subset—Solid (benda-benda padat), Danger (benda-benda berbahaya), dan Decorative (benda-benda dekoratif)—yang masing-masing memiliki konsekuensi berbeda dalam simulasi.

2.2.4 Convolutional Neural Network dan MobileNet

Convolutional Neural Network (CNN) merupakan arsitektur jaringan saraf tiruan yang dirancang khusus untuk pemrosesan data berbasis grid, seperti gambar. Arsitektur CNN memanfaatkan operasi konvolusi untuk mengekstraksi fitur hierarkis dari input: lapisan-lapisan awal menangkap fitur-fitur dasar seperti tepi dan tekstur, sementara lapisan-lapisan lebih dalam menangkap pola-pola kompleks seperti bentuk dan struktur objek. Kemampuan CNN untuk mempelajari representasi fitur secara otomatis dari data—tanpa memerlukan feature engineering manual—menjadikannya arsitektur dominan untuk tugas-tugas klasifikasi gambar, termasuk klasifikasi sketsa [6]. MobileNet merupakan varian CNN yang dikembangkan oleh Google dengan tujuan utama menghasilkan model yang ringan (lightweight) dan efisien untuk perangkat dengan sumber daya terbatas. Efisiensi MobileNet dicapai melalui dua mekanisme utama: (1) depthwise separable convolution, yang memecah operasi konvolusi standar menjadi depthwise convolution dan pointwise convolution, sehingga secara signifikan mengurangi jumlah parameter dan operasi komputasi; serta (2) dua hyperparameter—width multiplier (α) dan resolution multiplier (ρ)—yang memungkinkan penyesuaian trade-off antara akurasi dan efisiensi.

Penggunaan MobileNet dalam proyek ini didasarkan pada pertimbangan bahwa model harus dijalankan di client-side—yaitu di browser siswa melalui TensorFlow.js—tanpa bergantung pada server inferensi. MobileNet, dengan ukuran model sekitar beberapa megabyte dan kebutuhan komputasi yang jauh

BAB 3

DESKRIPSI SISTEM

Bab ini menyajikan deskripsi solusi dan desain sistem untuk proyek Sketchbook Universe yang berada dalam scope penulis (Dias), yaitu: Backend, REST API, Model CNN MobileNet, Penyimpanan Log SQLite, K-Means Clustering, Admin Dashboard, dan Kontrak Data Dias–Can. Modul Frontend, UI/UX, Probe UI, Animasi Momo, Level Design, dan Mekanisme HITL merupakan bagian pasangan penelitian (Can) yang dikerjakan oleh anggota tim lainnya. Bab ini disusun mengikuti urutan: deskripsi solusi, metodologi penelitian, desain sistem, pembagian tugas dan alur pengerjaan, serta jadwal penelitian. Penulis menekankan pada arsitektur backend, pipeline CNN, schema data log, endpoint REST API, algoritma K-Means, dan dashboard admin yang menjadi kontribusi inti scope penulis.

3.1 DESKRIPSI SOLUSI

Sketchbook Universe adalah simulasi interaktif berbasis web yang memfasilitasi interaksi reflektif siswa SMP terhadap output klasifikasi AI melalui mekanisme Human-in-the-Loop (HITL). Solusi ini dirancang berdasarkan empat prinsip teknis yang menjadi tanggung jawab penulis (Dias): (1) klasifikasi sketsa real-time menggunakan CNN MobileNet yang dikonversi ke TensorFlow.js untuk inferensi 100% client-side [6] [7] [8]; (2) pencatatan behavioral log terstruktur via REST API Node.js/Express ke database SQLite [4]; (3) analisis pola keputusan siswa menggunakan K-Means clustering [10] [11] un-

tuk segmentasi tipe pengambil keputusan; dan (4) dashboard admin untuk guru/superadmin yang memvisualisasikan metrik keputusan dan hasil clustering.

Dari perspektif scope penulis, sistem memiliki lima komponen teknis utama: (1) Model CNN MobileNet yang dilatih pada dataset Quick Draw! dengan 116 kategori terpilih (post-RSI-1 filter — kategori yang terlalu kompleks atau primitive dihapus) dan dikonversi ke format TensorFlow.js (model.json + shard files); (2) Backend REST API (Node.js + Express) yang menerima behavioral log dari frontend, memvalidasi payload, menyimpan ke SQLite, dan menyajikan endpoint query untuk dashboard; (3) Database SQLite yang menyimpan tabel `interaction_logs`, `sessions`, `students`, `classes`, `schools`, `guru`, `clusters`, dan `users`; (4) K-Means Worker (Python + scikit-learn) yang menjalankan clustering offline batch pada data log terkumpul; dan (5) Admin Dashboard yang memvisualisasikan metrik per kelas, per siswa, dan hasil clustering.

Post-pivot 16/6/26, terdapat empat perubahan signifikan pada scope penulis: (1) PIVOT #1 — penambahan aktor Superadmin dan hierarki user baru (Superadmin → Sekolah → Kelas → Siswa) mengharuskan penulis menambahkan tabel `schools`, `classes`, `guru` serta endpoint manajemen superadmin; login siswa menggunakan `class_id` + `nomor_absen` (no password), bukan gesture MediaPipe yang dideprecate; (2) PIVOT #2 — mekanisme Override Budget digantikan dengan Top-6 Check, sehingga backend wajib menyimpan field `top6_match` (boolean) dan field `confidence_top6` pada setiap log override; (3) DECISION #3 — penambahan timer count-up di frontend menambahkan field `time_spent_ms` pada setiap event log untuk analisis durasi per aksi; (4) DECISION #5 — kategori objek dipersempit menjadi Solid/Danger saja (Decorative dihapus), sehingga mapping table disederhanakan dan tabel `behavior_mapping` tidak lagi memuat kategori Decorative.

Kontrak data antara penulis (Dias) dan rekan (Can) berpusat pada dua titik temu: (1) Probe UI — tempat output AI (Top-3 + confidence dari

CNN) bertemu input user (keputusan siswa dari frontend); (2) Endpoint POST `/api/logs/event` — tempat frontend mengirim behavioral log ke backend. Kontrak data lengkap diuraikan pada Sub-bab 3.3.12. Selain menerima log, penulis juga menyediakan model CNN MobileNet yang telah dikonversi ke TensorFlow.js sebagai aset statis yang diloat oleh browser siswa saat aplikasi dibuka. Kontrak data ini memastikan bahwa rekan tidak perlu memahami detail training model, dan penulis tidak perlu memahami detail interaksi gameplay.

3.2 METODOLOGI PENELITIAN

Metodologi penelitian menjelaskan pendekatan, metode pengembangan, analisis masalah, teknik pengumpulan dan analisis data, serta metode pengujian yang digunakan dalam proyek ini. Pendekatan penelitian bersifat mixed methods dengan paradigma Research and Development (R&D). Metode pengembangan perangkat lunak mengikuti model Waterfall SDLC dengan lima tahap berurutan. Analisis masalah dilakukan menggunakan diagram Fish-bone (Ishikawa) dengan pendekatan 6M untuk mengidentifikasi root cause dari automation bias pada siswa SMP terhadap output AI. Pengumpulan data dilakukan melalui behavioral log sistem (yang dikirim ke backend penulis), akurasi model CNN via confusion matrix, dan kuesioner System Usability Scale (SUS) yang di-share dengan rekan. Analisis data menggunakan K-Means clustering untuk segmentasi pola perilaku siswa dan statistik deskriptif untuk akurasi model. Pengujian dilakukan dengan black-box testing, akurasi model (confusion matrix), dan SUS untuk dashboard admin.

3.2.1 Pendekatan dan Jenis Penelitian

Penelitian ini menggunakan pendekatan mixed methods [13] yang menggabungkan data kuantitatif (akurasi model CNN, behavioral log, skor SUS, metrik clustering) dan data kualitatif (interpretasi cluster, profil perilaku siswa per cluster). Pemilihan mixed methods didasarkan pada karakteristik proyek

yang mengukur performa teknis model (kuantitatif) sekaligus menginterpretasikan pola perilaku siswa hasil clustering (kualitatif). Creswell [13] menegaskan bahwa mixed methods cocok untuk penelitian yang membutuhkan triangulasi data dari multiple sources.

Jenis penelitian ini adalah Research and Development (R&D) [12], yaitu penelitian yang menghasilkan produk berupa sistem perangkat lunak (Sketchbook Universe bagian backend, CNN, dan analisis) beserta dokumentasi akademis. Sugiyono [12] mendefinisikan R&D sebagai metode penelitian yang digunakan untuk menghasilkan produk tertentu dan menguji keefektifan produk tersebut. Dalam konteks penulis, produk yang dikembangkan adalah model CNN MobileNet yang dikonversi ke TF.js, backend REST API dengan SQLite, pipeline K-Means clustering, dan admin dashboard yang diuji melalui confusion matrix, black-box testing, dan SUS.

3.2.2 Metode Pengembangan (Waterfall SDLC)

Metode pengembangan perangkat lunak yang digunakan adalah Waterfall SDLC [9] [10] dengan lima tahap berurutan: (1) Analisis Kebutuhan, (2) Perancangan Sistem, (3) Implementasi, (4) Integrasi dan Pengujian, dan (5) Pemeliharaan dan Dokumentasi. Pemilihan Waterfall didasarkan pada karakteristik proyek yang memiliki scope jelas, tim kecil (dua orang: Can dan Dias), serta kebutuhan dokumentasi akademis yang mensyaratkan setiap tahap terdefinisi secara eksplisit. Pressman [9] menegaskan bahwa Waterfall cocok untuk proyek dengan kebutuhan yang stabil dan tim yang dapat berkomitmen pada satu paradigma desain dari awal.

Gambar ?? menunjukkan diagram alur Waterfall SDLC yang diadaptasi untuk proyek Sketchbook Universe. Setiap tahap menghasilkan deliverable yang menjadi input bagi tahap berikutnya.

[Placeholder: Gambar Waterfall SDLC — 5 Tahap Berurutan — akan dilengkapi pada tahap implementasi]

Figure 3.1: Gambar 3.1 Metode Pengembangan Waterfall SDLC untuk Sketchbook Universe

Kelima tahap Waterfall diadaptasi untuk scope penulis (Dias) sebagai berikut:

Tahap 1 — Analisis Kebutuhan. Tahap ini mengidentifikasi kebutuhan backend: kebutuhan data log (Tabel 3.4), endpoint REST API (Tabel 3.5), schema database, model CNN MobileNet (Tabel 3.2), dan algoritma K-Means (Tabel 3.6). Output tahap ini meliputi dokumen kontrak data Can-Dias dan spesifikasi teknis backend.

Tahap 2 — Perancangan Sistem. Tahap ini menerjemahkan kebutuhan menjadi desain konkret: arsitektur sistem hybrid (browser inference + server-side services), perancangan model CNN, perancangan data log schema, perancangan backend API, perancangan K-Means clustering, perancangan admin dashboard, dan perancangan kontrak data. Output tahap ini meliputi seluruh sub-bab Desain Sistem (Sub-bab 3.3.1–3.3.12).

Tahap 3 — Implementasi. Tahap ini mengodekan desain menjadi sistem yang berjalan. Scope penulis (Dias) mencakup: training CNN MobileNet di Python/TensorFlow, konversi model ke TF.js, implementasi backend Node.js/Express, schema dan migrasi SQLite, K-Means worker Python, dan admin dashboard web.

Tahap 4 — Integrasi dan Pengujian. Tahap ini mengintegrasikan modul backend (scope penulis) dengan modul frontend (scope rekan Can) dan melakukan pengujian black-box, akurasi model via confusion matrix, dan SUS untuk dashboard admin. Titik integrasi utama adalah endpoint POST /api/logs/event dan POST /probe/override (Top-6 Check).

Tahap 5 — Pemeliharaan dan Dokumentasi. Tahap ini meliputi perbaikan bug yang ditemukan selama pengujian, optimasi model (quantization

bila ukuran > 5 MB), penulisan laporan akhir, dan dokumentasi kode sumber.

3.2.3 Analisis Masalah (Fishbone 6M)

Analisis masalah menggunakan diagram Fishbone (Ishikawa) [14] dengan pendekatan 6M untuk mengidentifikasi root cause dari permasalahan inti penelitian: automation bias pada siswa SMP terhadap output AI. Ishikawa [14] memperkenalkan diagram Fishbone sebagai alat analisis root cause yang mengkatégorikan faktor-faktor penyebab ke dalam enam dimensi (6M): Man, Method, Machine, Material, Measurement, dan Environment. Dari perspektif scope penulis (backend, CNN, K-Means), analisis 6M menekankan pada faktor teknis yang dapat diatasi melalui komponen backend.

Tabel 3.1 merinci keenam dimensi 6M beserta sub-cause yang teridentifikasi dan implikasi desain pada scope penulis.

Table 3.1: Analisis Masalah Automation Bias — Fishbone 6M (Perspektif Scope Dias)

Dimensi 6M	Sub-Cause Teridentifikasi	Implikasi Desain (Scope Dias)
Man (Manusia)	(1) Guru belum punya alat observasi pola keputusan siswa; (2) Peneliti belum punya dataset perilaku siswa terhadap AI klasifikasi sketsa; (3) Superadmin manual untuk multi-school deployment tidak scalable	Admin dashboard dengan decision distribution + K-Means cluster; behavioral log schema terstruktur; superadmin UI + endpoints untuk provisioning multi-school
Method (Metode)	(1) Tidak ada mekanisme anti-cheat untuk override siswa; (2) Tidak ada segmentasi tipe pengambil keputusan siswa; (3) Pembelajaran AI di SMP masih konseptual	Top-6 Check mechanism (backend verify); K-Means clustering dengan feature engineering per siswa; dataset behavioral log terstruktur
Machine (Mesin)	(1) Model CNN MobileNet memiliki confidence calibration belum sempurna; (2) Inferensi server-side memiliki latensi 200–500 ms; (3) Browser siswa heterogen	Training MobileNet V2 dengan transfer learning; inferensi 100% client-side via TF.js (15–100 ms); quantization model untuk loading cepat
Material (Materi)	(1) Dataset Quick Draw! terlalu luas (ratusan kategori); (2) Tidak ada dataset behavioral log siswa SMP terhadap AI; (3) Tidak ada lookup table perilaku objek untuk gameplay	Kurasi 116 kategori post-RSI-1 (medium difficulty); SQLite database interaction_logs; lookup table Solid/Danger (Decorative dihapus)
Measurement (Pengukuran)	(1) Tidak ada metrik standar untuk automation bias SMP; (2) Decision latency dan top6_match belum terdefinisi sebagai metrik; (3) Akurasi model belum dievaluasi via confusion matrix	Metrik: decision type distribution, time_spent_ms, top6_match_rate; confusion matrix untuk CNN (akurasi, precision, recall, F1); SUS untuk dashboard admin
Environment (Lingkungan)	(1) Bandwidth sekolah terbatas untuk streaming inferensi; (2) Device kelas berbagi, data harus terpisah antar sekolah; (3) Browser siswa heterogen	Inferensi 100% client-side (offline setelah model diloat); isolasi data antar sekolah (UU PDP No. 27/2022); model di-cache di browser siswa; SQLite embedded (no server DB setup)

Diagram Fishbone 6M lengkap ditunjukkan pada Gambar 3.2. Diagram menampilkan root cause (automation bias pada siswa SMP) di sisi kanan, dengan enam cabang utama 6M yang masing-masing memiliki 2–3 sub-cause.




Diagram Fishbone 6M selengkapnya juga tersedia dalam format Mermaid POLOSAN di file fishbone_6m.mmd (dirender terpisah ke PNG).

3.2.4 Teknik Pengumpulan Data

Pengumpulan data dilakukan melalui tiga teknik yang menjadi tanggung jawab scope penulis:

(1) Behavioral Log via REST API. Frontend Can mengirim setiap aksi siswa (draw, accept, correct, override, complete_level, fail_level) ke endpoint POST /api/logs/event (fire-and-forget pattern). Backend penulis menerima, memvalidasi, dan menyimpan ke tabel interaction_logs di SQLite. Setiap log memuat field baru post-pivot 16/6/26: time_spent_ms (durasi per aksi, dari timer count-up frontend), top6_match (boolean hasil Top-6 Check untuk override), dan confidence_top6 (confidence tertinggi dari Top-6 prediksi). Log ini merupakan sumber data utama untuk K-Means clustering dan dashboard guru.

(2) Confusion Matrix untuk Model CNN. Setelah training CNN MobileNet pada dataset Quick Draw! (116 kategori post-RSI-1), model dievaluasi menggunakan confusion matrix pada test set (20% dari dataset). Metrik yang diukur: akurasi global, precision per kategori, recall per kategori, dan F1-score per kategori. Target akurasi $\geq 85\%$ pada test set. Confusion matrix juga digunakan untuk mengidentifikasi kategori yang sering tertukar (mis: ladder vs fence) sebagai input untuk desain level (Level 2 ambiguity).

(3) SUS untuk Admin Dashboard. Setelah admin dashboard selesai, 2–3 guru mengisi kuesioner SUS [15] [16] untuk mengevaluasi usability dashboard. SUS dilakukan terpisah dari SUS frontend Can (yang ditujukan untuk siswa) karena target user berbeda (guru vs siswa). Target skor SUS dashboard ≥ 68 .

3.2.5 Teknik Analisis Data

Analisis data menggunakan dua teknik komplementer:

(1) K-Means Clustering untuk Behavioral Log. Behavioral log yang terkumpul di-feature engineering menjadi matriks fitur per siswa. Fitur yang diekstrak: `accept_rate`, `correct_rate`, `override_rate`, `mean_latency_ms` (dari `time_spent_ms`), `confidence_gap_mean`, `override_frequency`, dan `top6_match_rate` (rasio override yang diterima via Top-6 Check). Fitur dinormalisasi (z-score normalization) lalu di-cluster menggunakan K-Means. Jumlah cluster k ditentukan via elbow method dan silhouette score, kandidat $k = 3-5$. Hasil clustering menghasilkan segmentasi tipe pengambil keputusan siswa, misalnya: Cluster 1 — Tipe Pasif (Automation Bias Prone), Cluster 2 — Tipe Evaluatif (Calibrated Evaluator), Cluster 3 — Tipe Kritis (Overconfident Override). Detail teknis K-Means diuraikan pada Sub-bab 3.3.7.

(2) Statistik Deskriptif untuk Akurasi Model. Akurasi, precision, recall, dan F1-score dihitung dari confusion matrix. Persamaan 3.1–3.4 merumuskan keempat metrik tersebut.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.1)$$

$$\text{Precision} = \frac{TP}{TP + FP} \quad (3.2)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3.3)$$

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3.4)$$

3.2.6 Metode Pengujian

Pengujian sistem dilakukan dengan tiga metode:

(1) Black-Box Testing untuk Backend API. Pengujian fungsionalitas endpoint REST API dari perspektif input-output. Skenario mencakup: POST `/auth/login` (valid/invalid nomor absen), POST `/logs/event` (validasi pay-

load), POST /probe/override dengan Top-6 Check (match/no-match), POST /analysis/trigger-kmeans, GET /analysis/clusters/{class_id}, dan endpoint superadmin (Create School, Create Class, Generate Nomor Absen, Create Guru, Assign Guru to Class). Setiap skenario memiliki expected output yang didefinisikan sebelum pengujian.

(2) Akurasi Model via Confusion Matrix. Model CNN MobileNet dievaluasi pada test set dengan confusion matrix. Selain akurasi global, diukur precision, recall, dan F1-score per kategori. Kategori dengan F1-score rendah (< 0.70) diidentifikasi untuk iterasi training (data augmentation tambahan, hyperparameter tuning, atau penggantian kategori bila tidak dapat diperbaiki).

(3) SUS untuk Admin Dashboard. Pengujian usability dashboard dari perspektif guru (target user dashboard). SUS dilakukan dengan 2–3 guru yang mencoba fitur dashboard: View Class Dashboard, View Individual Student History, Trigger K-Means Analysis, View Cluster Distribution, Export Class Data. Target skor SUS ≥ 68 (above average menurut Bangor et al. [16]).

3.3 DESAIN SISTEM

Desain sistem menguraikan keputusan desain yang diambil berdasarkan prinsip-prinsip akademis dari Bab 2 dan hasil analisis Fishbone 6M pada Subbab 3.2.3. Setiap keputusan desain disertai dengan justifikasi teknis agar hubungan antara teori dan implementasi dapat ditelusuri secara eksplisit. Desain sistem meliputi: perancangan sistem global, arsitektur sistem, model CNN MobileNet, use case, data log schema, backend API, K-Means clustering, admin dashboard, sequence diagram, klasifikasi objek, technology stack, dan kontrak data Dias–Can.

3.3.1 Perancangan Sistem Global

Desain sistem global menggunakan model Input–Process–Output (IPO) yang terbagi menjadi empat layer proses: Interactive Simulation Layer, AI

Classification Layer, Decision & Consequence Layer, dan Data & Analysis Layer. Pembagian ini menunjukkan bahwa sistem terdiri dari blok fungsi utama yang saling terhubung, bukan satu flow panjang tanpa struktur.

Input berisi semua hal yang masuk ke sistem dari sisi user dan konteks permainan. Siswa memilih `class_id` dan nomor absen untuk login, menggambar objek di canvas, mengambil keputusan terhadap prediksi AI (Accept/Correct/Override), dan bermain di level tertentu. Post-pivot 16/6/26, login menggunakan nomor absen alih-alih gesture MediaPipe.

Interactive Simulation Layer adalah bagian yang membuat siswa masuk ke pengalaman sistem. Di sini ada onboarding, drawing canvas, Probe UI, gameplay 2D, dan feedback Momo. Layer ini dominan scope rekan (Can).

AI Classification Layer adalah bagian yang membaca gambar user. Gambar dari canvas masuk ke preprocessing, lalu diprediksi oleh CNN MobileNet di TensorFlow.js (client-side inference), kemudian menghasilkan Top-6 predictions dan confidence scores. Top-3 ditampilkan ke siswa (transparent), Top-4 s/d Top-6 disimpan internal untuk Top-6 Check (rahasia). Layer ini merupakan kontribusi scope penulis — training dan konversi model — yang dijalankan di browser siswa.

Decision & Consequence Layer adalah jembatan antara AI dan game. Setelah AI memberi prediksi, sistem tidak langsung menjalankan hasil AI. User masuk lewat Probe UI, lalu keputusan akhirnya menjadi final label. Final label itu baru dipetakan menjadi Solid atau Danger (Decorative dihapus post-pivot DECISION #5). Override memicu Top-6 Check di backend yang memutuskan auto-accept atau force redraw.

Data & Analysis Layer menerima log dari proses interaksi dan gameplay. Data dikirim via REST API ke backend, disimpan di SQLite, lalu diproses untuk analisis pola keputusan. K-Means clustering dijalankan di server menggunakan Python (scikit-learn). Dashboard guru memvisualisasikan hasil analisis. Layer ini dominan scope penulis.

Catatan penulis: Gambar diagram IPO Global akan dibuat manual

oleh penulis pada tahap implementasi menggunakan draw.io atau Figma.

[Placeholder: Gambar Desain Sistem Global IPO — 4 Layer — akan dilengkapi pada tahap implementasi]

Figure 3.3: Gambar 3.3 Desain Sistem Global Input Process Output 4 Layer Sketchbook Universe

3.3.2 Perancangan Arsitektur Sistem Hybrid

Proyek ini mengadopsi pola Hybrid Architecture yang menggabungkan Browser-Based Inference untuk klasifikasi AI dan Server-Side Services untuk layanan pendukung. Inferensi CNN MobileNet berjalan sepenuhnya di browser siswa menggunakan TensorFlow.js, sehingga data gambar siswa tidak pernah keluar dari perangkat mereka. Di sisi lain, server backend (Node.js/Express + SQLite) menangani layanan yang memerlukan persistensi, autentikasi, analisis, dan visualisasi — termasuk REST API logging, JWT authentication untuk dashboard guru, K-Means clustering, dan ekspor data.

Pemisahan ini bukan arbitrer. Inferensi dikategorikan client-side karena dua alasan: (1) privasi data siswa — gambar tidak keluar device, sesuai COPPA/GDPR-K; (2) latensi rendah (15–100 ms vs 200–500 ms jika lewat server). Layanan pendukung dikategorikan server-side karena memerlukan persistensi data lintas sesi, akses terpusat oleh guru, dan komputasi analisis yang tidak perlu real-time di browser siswa.

Dari sisi penulis (scope Dias), arsitektur backend terdiri dari komponen-komponen berikut:

(1) REST API (Node.js/Express). Endpoint utama meliputi POST /api/logs/event untuk menerima log dari frontend, POST /probe/override untuk Top-6 Check, GET /api/sessions untuk mengambil daftar sesi, GET /api/sessions/:id/metrics untuk mengambil metrik keputusan, GET /api/export/csv dan GET /api/export/json untuk ekspor data. Endpoint superadmin (post-pivot 16/6/26) meliputi POST /api/superadmin/schools, POST /api/superadmin/classes,

POST /api/superadmin/students/generate, POST /api/superadmin/guru, POST /api/superadmin/assign-guru. API menggunakan JWT authentication untuk melindungi akses dashboard guru dan superadmin.

(2) SQLite Database. Menyimpan interaction log, session data, students, classes, schools, guru, users, dan clusters. SQLite dipilih karena ringan, tanpa konfigurasi server tambahan, dan cukup untuk skala data penelitian (puluhan siswa, bukan ribuan).

(3) K-Means Clustering (Python/scikit-learn). Menerima data log yang telah di-feature engineering, menjalankan K-Means clustering untuk mengelompokkan tipe pengambil keputusan siswa, dan menghasilkan label cluster. Python dipilih karena scikit-learn menyediakan implementasi K-Means yang matang dan interoperabilitas dengan pandas untuk feature engineering.

(4) Admin Dashboard. Panel web yang memvisualisasikan metrik keputusan siswa dan hasil clustering. Dashboard mengakses data melalui REST API yang sama, sehingga guru tidak perlu akses langsung ke database.

(5) Model File Serving. Server menyajikan aset model TensorFlow.js (model.json + shard files) sebagai file statis. Model diloat oleh browser siswa saat pertama kali membuka aplikasi, lalu di-cache untuk sesi berikutnya. Server tidak menjalankan inference — ia hanya menyediakan file model.

Catatan penulis: Gambar diagram arsitektur akan dibuat manual oleh penulis pada tahap implementasi.

[Placeholder: Gambar Arsitektur Sistem Hybrid — Browser Inference + Server Services — akan dilengkapi pada tahap implementasi]

Figure 3.4: Gambar 3.4 Arsitektur Sistem Hybrid Browser-Based Inference dan Server-Side Services

3.3.3 Perancangan Model CNN MobileNet

Model klasifikasi gambar menggunakan arsitektur CNN MobileNet V2 sebagai backbone. MobileNet dipilih karena dirancang untuk perangkat den-

gan resource terbatas — termasuk browser — tanpa mengorbankan akurasi secara signifikan [6]. Model dilatih menggunakan dataset Quick Draw! dari Google [7] dengan 116 kategori terpilih (post-RSI-1 filter).

Pemilihan Kategori Dataset (116 Kategori Post-RSI-1)

Dari ratusan kategori yang tersedia di Quick Draw!, dipilih 116 kategori yang memenuhi kriteria RSI-1 (post-pivot 16/6/26): (1) bukan geometric primitive (line, circle, square, triangle — dihapus total); (2) bukan hewan (cat, dog, elephant, dll — dihapus untuk menghindari confusion matrix antar hewan); (3) bukan landmark/kompleks ekstrem (Eiffel Tower, Mona Lisa, Great Wall — dihapus); (4) bukan single-stroke (smiley face, eye, dot — dihapus). Yang dipertahankan: everyday objects (clock, cup, hat, key, umbrella), simple food (apple, donut, pizza slice), nature (sun, moon, star, tree, flower, cloud), dan basic vehicles (car, bus, bicycle) — semua dengan stroke 4–15.

Setiap kategori harus dapat dipetakan ke salah satu dari dua behavior (Solid atau Danger; Decorative dihapus post-pivot DECISION #5) dan memiliki minimal 50.000 sampel di Quick Draw! untuk training. Contoh kategori Solid: ladder, bridge, chair, table, plank. Contoh kategori Danger: knife, sword, axe, duri (thorns — bukan pisau, sesuai arahan Bu Hesti). Pemilihan kategori ini memastikan bahwa setiap level bisa menghasilkan confidence range yang berbeda secara programatik.

Arsitektur Model (MobileNet V2 + Transfer Learning)

Model menggunakan MobileNet V2 sebagai feature extractor, dengan layer klasifikasi kustom di atasnya. Input berupa gambar grayscale 28×28 piksel (sesuai format Quick Draw!). Preprocessing meliputi: resize, normalisasi (0–1), konversi grayscale ke RGB 3-channel (kompatibilitas dengan MobileNet V2 input shape), dan konversi ke tensor. Output berupa probabilitas untuk 116 kategori menggunakan softmax.

Hyperparameter awal ditunjukkan pada Tabel 3.2.

Table 3.2: Hyperparameter CNN MobileNet V2 — Initial Value

Hyperparameter	Nilai Awal
Feature Extractor	MobileNet V2 (pre-trained ImageNet)
Epoch	100
Learning Rate	0.001
Optimizer	Adam
Loss Function	Categorical crossentropy
Batch Size	32
Data Augmentation	Rotasi $\pm 15^\circ$, flip horizontal, zoom $\pm 10\%$
Train/Test Split	80/20
Target Akurasi	$\geq 85\%$ pada test set

Nilai hyperparameter bersifat fleksibel dan dapat disesuaikan berdasarkan hasil evaluasi performa model pada data uji. Bila akurasi belum mencapai target 85%, dilakukan iterasi: (1) tambah data augmentation, (2) tune learning rate (0.0005 atau 0.0001), (3) unfreeze beberapa layer MobileNet V2 untuk fine-tuning, (4) ganti kategori dengan F1-score rendah.

Konversi ke TensorFlow.js

Setelah model mencapai akurasi yang memadai ($\geq 85\%$), model dikonversi dari format Keras (.h5) ke format TensorFlow.js menggunakan tensorflowjs_converter. Konversi menghasilkan file model.json (metadata model) dan shard files (bobot model). File-file ini disajikan sebagai aset statis oleh server dan di-load oleh browser siswa saat aplikasi dibuka.

Target ukuran model setelah konversi adalah < 5 MB agar loading time di browser tetap cepat. Jika ukuran melebihi target, dilakukan quantization (float16 atau int8) untuk mengurangi ukuran file. Smilkov et al. [8] menegaskan bahwa TF.js memungkinkan inferensi CNN di browser dengan latency 15–100 ms untuk model berukuran < 5 MB, sehingga inferensi real-time di gameplay dapat berjalan tanpa blocking.

[Placeholder: Gambar Arsitektur CNN MobileNet V2 — Training ke TF.js Export — akan dilengkapi pada tahap implementasi]

Figure 3.5: Gambar 3.5 Arsitektur CNN MobileNet V2 dari Training ke Konversi TensorFlow.js

3.3.4 Perancangan Use Case

Use case diagram memetakan aktor eksternal dan tujuan utama sistem. Post-pivot 16/6/26 (PIVOT #1), terdapat tiga aktor utama: Siswa, Guru/Admin Sekolah, dan Superadmin. Aktor Superadmin merupakan aktor baru yang ditambahkan untuk mendukung deployment multi-sekolah dan pengelolaan nomor absen siswa per kelas. Sistem memiliki total 30 use case (UC-01 s/d UC-30) yang terdistribusi pada tiga aktor. Daftar lengkap 30 use case beserta deskripsinya telah diuraikan pada Bab 3 Can (Sub-bab Use Case Sistem) karena bersifat shared — kedua proposal merujuk pada use case yang sama. Tabel 3.3 merangkum use case yang berada di tanggung jawab scope penulis (Dias).

Table 3.3: Use Case yang Menjadi Tanggung Jawab Scope Dias

ID	Nama Use Case	Aktor	Implikasi Backend (Scope Dias)
UC-05	Generate Nomor Absen Siswa	Superadmin	Endpoint POST /api/superadmin/students/generate, INSERT N slot siswa kosong
UC-06	Create Guru Account	Superadmin	Endpoint POST /api/superadmin/guru, hash password bcrypt
UC-07	Assign Guru to Class	Superadmin	Endpoint POST /api/superadmin/assign-guru, mapping guru_class
UC-12	Login Guru	Guru	Endpoint POST /api/auth/login/guru, JWT generation
UC-14	View Class Dashboard	Guru	Endpoint GET /api/dashboard/{class_id}, agregasi metrik per kelas
UC-15	View Individual Student History	Guru	Endpoint GET /api/students/{student_id}/history
UC-16	Export Class Data	Guru	Endpoint GET /api/export/csv dan /api/export/json
UC-17	Trigger K-Means Analysis	Guru	Endpoint POST /api/analysis/trigger-kmeans, submit job ke K-Means Worker
UC-18	View Cluster Distribution	Guru	Endpoint GET /api/analysis/clusters/{class_id}
UC-21	Login Nomor Absen	Siswa	Endpoint POST /api/auth/login, no password, JWT 4 jam expiry
UC-28	Override Prediction	Siswa	Endpoint POST /probe/override, Top-6 Check di backend

Use case yang bersifat frontend-only (UC-22 View Onboarding, UC-23 Start Level, UC-24 Draw Object, UC-25 View AI Prediction, UC-26 Accept, UC-27 Correct, UC-29 Top-6 Verification Result, UC-30 View Personal History) berada di tanggung jawab rekan (Can). Namun, use case UC-24, UC-26, UC-27, dan UC-28 menghasilkan behavioral log yang dikirim ke backend penulis via POST /api/logs/event, sehingga penulis wajib menyediakan endpoint penerima dan schema penyimpanan yang sesuai.

3.3.5 Perancangan Data Log Schema

Log interaksi menyimpan data utama dari momen Human-in-the-Loop: prediksi AI, confidence, keputusan siswa, final label, behavior objek, hasil gameplay, waktu keputusan, dan hasil Top-6 Check. Schema ini dirancang untuk mendukung analisis pola keputusan dan K-Means clustering. Tabel 3.4 merinci struktur JSON interaction log yang dikirim dari frontend ke backend.

Table 3.4: Struktur JSON Interaction Log (Post-Pivot 16/6/26)

Field	Typ	Deskripsi
session_token	String (JWT)	Token sesi siswa, validasi via POST /api/auth/login
student_id	Integer	ID siswa (di-derive dari session_token di backend)
class_id	Integer	ID kelas siswa
school_id	Integer	ID sekolah siswa (untuk isolasi data)
level	Integer	Level permainan (1, 2, 3)
probe_id	String	ID unik per momen Probe UI
event_type	String	Jenis event: draw_start, draw_end, accept, correct, override, move_stickman, complete_level, fail_level
decision_type	String (nullable)	Accept / Correct / Override (hanya untuk event accept/correct/override)
top3_predictions	Array[String]	Tiga prediksi teratas dari CNN (ditampilkan ke siswa)
confidence_scores	Array[Float]	Confidence score per prediksi (0–1)
confidence_top1	Float	Confidence tertinggi (Top-1)
confidence_top6	Float	Confidence tertinggi dari Top-6 (NEW post-pivot)
override_label	String (nullable)	Label yang diinput siswa saat Override
top6_match	Boolean (nullable)	Hasil Top-6 Check: true bila override_label ada di Top-6 (NEW post-pivot)
final_label	String	Label akhir setelah keputusan siswa
object_behavior	String	Solid / Danger (Decorative dihapus post-pivot)
gameplay_result	String (nullable)	Success / Fail / Retry (hanya untuk complete_level, fail_level)
time_spent_ms	Integer	Durasi aksi dalam milidetik (NEW post-pivot Decision #3, dari timer count-up)
timestamp	String (ISO 8601)	Waktu kejadian

Field time_spent_ms, confidence_top6, dan top6_match merupakan tambahan baru post-pivot 16/6/26 yang memungkinkan analisis durasi per aksi (dari timer count-up frontend) dan evaluasi kewajaran label override (dari Top-6 Check). Field object_behavior hanya berisi solid atau danger (Decorative dihapus post-pivot).

tive dihapus). Schema SQLite merefleksikan struktur JSON ini dengan tabel `interaction_logs` yang memiliki kolom sesuai field di atas.

3.3.6 Perancangan Backend API

Backend API dibangun menggunakan Node.js dengan framework Express.js. Database menggunakan SQLite yang diakses melalui ORM Sequelize (untuk konsistensi schema dan migrasi). Autentikasi menggunakan JWT dengan dua tipe token: token siswa (4 jam expiry, login via nomor absen) dan token guru/superadmin (8 jam expiry, login via username + password). Hashing password guru menggunakan bcrypt.

Tabel 3.5 merinci daftar endpoint REST API yang disediakan scope penulis.

Table 3.5: Daftar Endpoint REST API (Post-Pivot 16/6/26)

Method	Endpoint	Deskripsi	Auth
POST	/api/auth/login	Login siswa (class_id + nomor_absen, no password)	Tidak
POST	/api/auth/login/guru	Login guru (username + password)	Tidak
POST	/api/auth/login/superadmin	Login superadmin	Tidak
POST	/api/logs/event	Menerima interaction log dari frontend (fire-and-forget)	JWT Siswa
POST	/probe/override	Top-6 Check untuk override (auto-accept atau redraw)	JWT Siswa
GET	/api/classes	Daftar kelas aktif (untuk dropdown login siswa)	Tidak
GET	/api/dashboard/{class_id}	Dashboard analitik per kelas	JWT Guru
GET	/api/students/{student_id}	History permainan siswa individual	JWT Guru
GET	/api/export/csv	Ekspor data log kelas (CSV)	JWT Guru
GET	/api/export/json	Ekspor data log kelas (JSON)	JWT Guru
POST	/api/analysis/trigger-kmeans	Submit job K-Means clustering untuk kelas	JWT Guru
GET	/api/analysis/clusters/{class_id}	Hasil K-Means clustering kelas	JWT Guru
POST	/api/superadmin/schools	Create school	JWT Superadmin
POST	/api/superadmin/classes	Create class	JWT Superadmin
POST	/api/superadmin/students/generate	Generate N slot nomor absen	JWT Superadmin
POST	/api/superadmin/guru	Create guru account	JWT Superadmin
POST	/api/superadmin/assign-guru	Assign guru to class	JWT Superadmin
GET	/api/superadmin/schools/overview	View all schools overview	JWT Superadmin

Endpoint POST /api/logs/event dan POST /probe/override tidak memerlukan JWT guru karena dipanggil oleh browser siswa secara otomatis — namun keduanya memerlukan JWT siswa (diperoleh dari POST /api/auth/login) untuk memvalidasi session dan mengaitkan log dengan student_id yang benar. Endpoint GET /api/classes tidak memerlukan auth karena dibutuhkan untuk dropdown login siswa sebelum autentikasi. Endpoint lainnya memerlukan

JWT guru atau superadmin sesuai hierarki user.

Alur Logging (Fire-and-Forget)

Alur logging dimulai ketika frontend mengirim interaction event ke backend. Backend menerima event, memvalidasi JWT siswa (ekstrak `student_id`, `class_id`, `school_id`), memvalidasi payload (cek field wajib dan tipe data), menyimpan ke SQLite, dan mengembalikan 204 No Content ke frontend. Jika payload tidak valid, backend mengembalikan 400 Bad Request dengan pesan deskriptif. Pengiriman bersifat asynchronous — frontend tidak menunggu respons sebelum melanjutkan gameplay. Pola fire-and-forget ini memastikan gameplay siswa tidak terblokir oleh latency jaringan.

Alur Top-6 Check (POST /probe/override)

Endpoint POST /probe/override menerima payload {`session_token`, `drawing_blob_url`, `top6`, `override_label`, `level`, `probe_id`, `time_spent_ms`}. Backend melakukan langkah berikut: (1) validasi JWT siswa; (2) case-insensitive match antara `override_label` dengan `top6[].label`; (3) bila match → INSERT log dengan `top6_match=true`, return 200 OK {`accepted: true`, `reason: top6_match`}; (4) bila no-match → INSERT log dengan `top6_match=false`, return 200 OK {`accepted: false`, `reason: top6_no_match`, `action: redraw`}. Field `time_spent_ms` disimpan untuk analisis durasi aksi override.

[Placeholder: Gambar Backend Logging Flow — akan dilengkapi pada tahap implementasi]

Figure 3.6: Gambar 3.6 Backend Logging Flow dan Top-6 Check Flow

3.3.7 Perancangan K-Means Clustering

K-Means clustering digunakan untuk mengelompokkan siswa berdasarkan pola keputusan mereka terhadap output AI [10] [11]. Tujuannya bukan hanya

deskriptif flat (“sekian persen siswa Override”), tetapi menghasilkan segmentasi tipe pengambil keputusan yang bermakna secara akademis. Pendekatan ini meningkatkan kontribusi penelitian karena output analisisnya tidak hanya berupa angka agregat, tetapi juga profil perilaku siswa.

Input K-Means (Feature Engineering)

Input K-Means adalah matriks fitur yang telah di-feature engineering dan dinormalisasi. Tabel 3.6 merinci fitur-fitur yang diekstrak per siswa.

Table 3.6: Feature Engineering untuk K-Means Clustering (per Siswa)

Fitur	Rumus	Interpretasi
accept_rate	$\text{count}(\text{accept}) / \text{total_decisions}$	Tingkat kecenderungan menerima AI
correct_rate	$\text{count}(\text{correct}) / \text{total_decisions}$	Tingkat evaluasi alternatif
override_rate	$\text{count}(\text{override}) / \text{total_decisions}$	Tingkat penolakan AI
mean_latency_ms	$\text{mean}(\text{time_spent_ms})$	Rata-rata durasi keputusan
confidence_gap_mean	$\text{mean}(\text{conf_top1} - \text{conf_top2})$	Rata-rata ambiguitas prediksi
override_frequency	$\text{count}(\text{override}) / \text{total_probes}$	Frekuensi override per probe
top6_match_rate	$\text{count}(\text{top6_match}=\text{true}) / \text{count}(\text{override})$	Rasio override yang masuk akal (NEW post-pivot)
risk_acceptance_rate	$\text{count}(\text{accept pada conf} < 50\%) / \text{total_accept}$	Tingkat automation bias (Accept cepat pada conf rendah)
fail_rate	$\text{count}(\text{fail_level}) / \text{total_levels_played}$	Tingkat kegagalan level

Fitur-fitur ini dinormalisasi (z-score normalization) sebelum digunakan sebagai input K-Means untuk menghindari bias akibat perbedaan skala antar fitur. Field top6_match_rate merupakan fitur baru post-pivot PIVOT #2 yang memungkinkan analisis kewajaran override siswa — siswa dengan top6_match_rate rendah cenderung gambar carelessly dan memasukkan label acak.

Penentuan Jumlah Cluster (Elbow Method + Silhouette)

Jumlah cluster (k) ditentukan menggunakan metode Elbow dan Silhouette Score. Elbow method memplot Within-Cluster Sum of Squares (WCSS) terhadap jumlah cluster, dan titik siku (elbow) menunjukkan jumlah cluster optimal. Silhouette Score mengukur seberapa baik setiap data point berada di cluster-nya dibandingkan cluster lain. Nilai Silhouette Score mendekati 1 menunjukkan clustering yang baik. Berdasarkan literatur dan ekspektasi awal, kandidat jumlah cluster adalah 3–5.

Proses K-Means (Offline Batch)

Proses K-Means dilakukan secara offline di server menggunakan Python scikit-learn. Data log yang telah terkumpul di-export dari SQLite, di-feature engineering, dinormalisasi, lalu di-cluster. Hasil clustering (label cluster per sesi, centroid, dan metrik evaluasi) disimpan kembali ke database (tabel clusters) untuk diakses melalui dashboard.

K-Means dijalankan secara batch, bukan real-time. Setelah sesi permainan selesai dan data log terkumpul, guru dapat memicu analisis clustering melalui dashboard (POST /api/analysis/trigger-kmeans). Alternatif lain, clustering dijalankan secara otomatis (cron job 23:00 daily) bila jumlah sesi mencapai threshold minimum (misalnya 10 sesi per kelas).

Interpretasi Cluster (Hipotesis Awal)

Setiap cluster diinterpretasikan berdasarkan centroid-nya. Hipotesis interpretasi cluster (akan diverifikasi setelah data penelitian terkumpul):

- Cluster 1 — Tipe Pasif (Automation Bias Prone). Accept Rate tinggi ($> 70\%$), Override Rate rendah ($< 10\%$), mean latency rendah (< 3000 ms), risk_acceptance_rate tinggi. Siswa cenderung menerima prediksi AI tanpa mengevaluasi, terutama pada confidence rendah.

- Cluster 2 — Tipe Evaluatif (Calibrated Evaluator). Correct Rate signifikan, mean latency sedang (4000–6000 ms), risk_acceptance_rate rendah, top6_match_rate tinggi. Siswa mempertimbangkan prediksi alternatif dan melakukan Correct saat confidence ambigu.
- Cluster 3 — Tipe Kritis (Overconfident Override). Override Rate tinggi ($> 30\%$), mean latency tinggi (> 7000 ms), top6_match_rate bervariasi (mengindikasikan beberapa override tidak masuk akal), fail_rate bervariasi. Siswa aktif menolak prediksi AI, terutama di Level 3.

Interpretasi ini bersifat hipotesis awal dan akan diverifikasi setelah data penelitian terkumpul. Label cluster tidak ditentukan sebelumnya — K-Means adalah unsupervised learning, sehingga cluster muncul dari data, bukan dari asumsi peneliti.

[Placeholder: Gambar Pipeline K-Means Clustering — dari Data Log ke Segmentasi — akan dilengkapi pada tahap implementasi]

Figure 3.7: Gambar 3.7 Pipeline K-Means Clustering dari Data Log ke Segmentasi Tipe Pengambil Keputusan Siswa

3.3.8 Perancangan Admin Dashboard

Admin dashboard digunakan untuk membaca data interaksi siswa dari sesi permainan. Panel ini membantu guru melihat pola keputusan terhadap AI dan superadmin mengelola entitas sekolah/kelas/guru/siswa. Post-pivot 16/6/26, dashboard terbagi menjadi dua panel: Guru Dashboard (untuk aktor Guru) dan Superadmin Dashboard (untuk aktor Superadmin).

Guru Dashboard

Guru Dashboard menampilkan analitik per kelas yang ditugaskan kepada guru. Fitur utama meliputi:

- Session List — Daftar sesi permainan yang telah dilakukan, dengan filter level dan rentang tanggal.
- Decision Metrics — Visualisasi metrik keputusan per kelas: Accept Rate, Correct Rate, Override Rate, Top-6 Match Rate, Confidence vs Decision (scatter plot), dan Gameplay Result distribution.
- Clustering Result — Visualisasi hasil K-Means clustering: scatter plot 2D (PCA/t-SNE reduction), distribusi cluster, dan profil per cluster.
- Export Data — Ekspor data log ke CSV atau JSON untuk analisis lebih lanjut di tools eksternal.

Superadmin Dashboard

Superadmin Dashboard (BARU post-pivot 16/6/26) menampilkan overview multi-sekolah dan form provisioning entitas. Fitur utama meliputi:

- Schools Overview — Daftar seluruh sekolah yang terdaftar dengan ringkasan: jumlah kelas, jumlah guru, jumlah siswa aktif, total sesi permainan.
- Classes per School — Drill-down ke kelas per sekolah.
- Create School Form — Input nama sekolah, alamat, jenjang.
- Create Class Form — Input nama kelas di bawah sekolah tertentu.
- Generate Nomor Absen Form — Tentukan jumlah slot nomor absen per kelas.
- Create Guru Account Form — Input username, password, nama lengkap, sekolah induk.
- Assign Guru to Class — Pilih guru dan kelas yang akan ditugaskan (maks 2 guru per kelas untuk co-teaching).

[Placeholder: Wireframe Guru Dashboard — akan dilengkapi pada tahap implementasi]

Figure 3.8: Gambar 3.8 Wireframe Guru Dashboard Session List Decision Metrics Clustering Result Export Data

[Placeholder: Wireframe Superadmin Dashboard — akan dilengkapi pada tahap implementasi]

Figure 3.9: Gambar 3.9 Wireframe Superadmin Dashboard Schools Overview Create School Create Class Generate Nomor Absen Create Guru Assign Guru Post-Pivot
16 Juni 2026

3.3.9 Perancangan Sequence Diagram

Sequence diagram menunjukkan komunikasi antar komponen saat siswa menggambar, AI memberi prediksi, siswa menentukan final label, game menampilkan konsekuensi, dan backend menyimpan log. Tiga sequence diagram key flows sistem (Login, Override + Top-6 Check, Data Logging) telah diuraikan pada Bab 3 Can (Sub-bab Alur Pengguna) karena bersifat shared — kedua proposal merujuk pada sequence diagram yang sama. Diagram-diagram tersebut merinci interaksi antar komponen: Siswa, Frontend (Kplay.js), CNN Model (TF.js), Backend API (Node.js), Database (SQLite), dan K-Means Worker (Python).

Dari perspektif scope penulis, tiga titik kritis sequence diagram adalah: (1) Login Flow — validasi nomor absen di backend, generate JWT 4 jam, INSERT session; (2) Override + Top-6 Check Flow — validasi override_label vs top6 di backend, INSERT log dengan field top6_match; (3) Data Logging Flow — fire-and-forget pattern, INSERT interaction_logs, offline batch K-Means clustering oleh Guru via POST /api/analysis/trigger-kmeans.

[Placeholder: Sequence Diagram — Login Flow Siswa ke Backend — akan dilengkapi pada tahap implementasi]

Figure 3.10: Gambar 3.10 Sequence Diagram Login Flow Siswa Frontend Backend Database

[Placeholder: Sequence Diagram — Override + Top-6 Check Flow — akan dilengkapi pada tahap implementasi]

Figure 3.11: Gambar 3.11 Sequence Diagram Override dan Top-6 Check Flow Siswa Frontend CNN Backend Database

[Placeholder: Sequence Diagram — Data Logging Flow ke K-Means Offline Batch — akan dilengkapi pada tahap implementasi]

Figure 3.12: Gambar 3.12 Sequence Diagram Data Logging Flow Frontend Backend Database K-Means Worker Offline Batch

3.3.10 Perancangan Klasifikasi Objek (Solid / Danger)

Setiap gambar yang diklasifikasi oleh CNN mendapatkan label, dan label tersebut dipetakan ke salah satu dari dua kategori behavior yang menentukan dampak objek dalam gameplay. Pemetaan ini bersifat otomatis berdasarkan kategori Quick Draw! yang dipilih. Pemetaan label ke behavior dilakukan menggunakan lookup table yang didefinisikan berdasarkan 116 kategori yang dipilih dari dataset Quick Draw! (post-RSI-1 filter).

Post-pivot DECISION #5 16/6/26, kategori Decorative dihapus. Hanya tersisa dua kategori:

- Solid — Objek yang bisa dipijak, membentuk platform, atau membantu Stickman bergerak maju. Contoh: ladder, bridge, chair, table, plank, staircase.

- Danger — Objek yang menyebabkan gagal atau reset. Contoh: knife, sword, axe, duri (thorns — bukan pisau, sesuai arahan Bu Hesti), scissors, fire.

Penghapusan kategori Decorative memastikan konsekuensi gameplay bersifat biner dan jelas bagi siswa SMP: setiap objek yang masuk game world pasti memiliki efek (membantu atau membahayakan Stickman). Tidak ada lagi objek netral yang memaksa siswa menggambar ulang tanpa feedback jelas.

Lookup table bersifat statis dan tidak berubah selama permainan berlangsung. Sistem tidak melakukan fine-tuning dari data override siswa — data log hanya digunakan untuk analisis penelitian. Tabel 3.7 menunjukkan contoh pemetaan label ke behavior.

Table 3.7: Contoh Pemetaan Label ke Behavior (Post-Pivot Decorative Dihapus)

Label	Behavior
ladder	Solid
bridge	Solid
chair	Solid
table	Solid
plank	Solid
knife	Danger
sword	Danger
axe	Danger
duri (thorns)	Danger
scissors	Danger

3.3.11 Perancangan Technology Stack

Technology stack untuk scope penulis (backend dan AI) dipilih berdasarkan kebutuhan analisis, stabilitas, dan interoperabilitas. Tabel 3.8 merinci stack yang digunakan.

Table 3.8: Technology Stack Scope Dias

Komponen	Teknologi	Alasan
CNN Training	TensorFlow 2.x / Keras	Ekosistem matang, MobileNet V2 pre-trained tersedia, integrasi dengan TF.js converter
Model Export	tensorflowjs_converter	Konversi .h5 ke TF.js format (model.json + shard files)
Backend API	Node.js 18+ + Express 4.x	Ringan, async I/O, kompatibel dengan JSON, ekosistem npm matang
Database	SQLite 3.x	Tanpa konfigurasi server tambahan, cukup untuk skala riset, embedded
ORM	Sequelize 6.x	Konsistensi schema, migrasi, query builder
Authentication	JWT (jsonwebtoken)	Standar, stateless, mudah diimplementasi
Password Hashing	bcrypt	Standar industri untuk hashing password guru
Clustering	Python 3.10+ + scikit-learn 1.x	Implementasi K-Means matang, elbow method + silhouette score built-in
Data Processing	pandas 2.x + numpy	Feature engineering, normalisasi z-score, manipulasi matriks fitur
Dashboard Frontend	React 18 + Vite	Konsistensi dengan frontend Can, komponen reusable
Dashboard Charting	Chart.js atau Recharts	Visualisasi bar chart, scatter plot, line chart untuk dashboard guru

TensorFlow/Keras dipilih untuk training karena menyediakan arsitektur MobileNet V2 yang sudah pre-trained dan bisa di-fine-tune pada dataset Quick Draw!. Python dipilih untuk analisis K-Means karena scikit-learn menyediakan pipeline yang lengkap (preprocessing, clustering, evaluasi). Node.js/Express dipilih untuk backend API karena ringan, mendukung asynchronous I/O, dan kompatibel dengan format JSON yang digunakan di seluruh sistem. SQLite dipilih karena embedded (tidak perlu server DB setup) dan cukup untuk skala data penelitian. React dipilih untuk dashboard frontend agar konsisten dengan frontend Can (yang juga berbasis React/Kaplay.js).

3.3.12 Perancangan Kontrak Data Dias–Can

Kontrak data menjelaskan batas tanggung jawab antara scope penulis (Dias) dan scope rekan (Can). Rekan bertanggung jawab membentuk interaction event di frontend dan mengirimkannya ke backend via REST API. Penulis bertanggung jawab menerima event, menyimpan ke database, dan melakukan analisis.

Data yang diterima penulis dari frontend berformat JSON dengan struktur yang telah diuraikan pada Tabel 3.4. Endpoint utama yang digunakan adalah POST `/api/logs/event` (untuk semua event behavioral) dan POST `/probe/override` (untuk override + Top-6 Check). Frontend mengirim data secara asynchronous setelah setiap momen HITL selesai, sehingga pengiriman data tidak memblokir gameplay. Backend melakukan validasi payload sebelum menyimpan ke database.

Selain menerima log, penulis juga menyediakan model CNN MobileNet yang telah dikonversi ke TensorFlow.js. Model disajikan sebagai aset statis oleh server dan di-load oleh browser siswa saat aplikasi dibuka. Kontrak data ini memastikan bahwa rekan tidak perlu memahami detail training model, dan penulis tidak perlu memahami detail interaksi gameplay.

Pembagian kerja dalam proyek ini tidak terpisah secara ketat. Penulis menyiapkan model AI, output prediksi, backend log, dan analisis. Rekan merancang pengalaman interaksi dan gameplay. Keduanya bertemu di Probe UI sebagai momen Human-in-the-Loop. Probe UI adalah titik temu di mana output dari AI (Top-3 + confidence) dan input dari user (keputusan) bergabung, kemudian menghasilkan gameplay consequence dan interaction event.

Tabel 3.9 merangkum kontrak data Dias–Can secara ringkas.

Table 3.9: Kontrak Data Dias–Can (Ringkas)

Aspek	Tanggung Jawab Can	Tanggung Jawab Dias
Probe UI Input	Tampilkan Top-3, terima keputusan siswa	Sediakan Top-3 + Top-6 dari CNN (TF.js)
Override Payload	Pack JSON, kirim POST /probe/override	Validasi, Top-6 Check, return auto-accept/redraw
Behavioral Log	Pack event, kirim POST /api/logs/event	Validasi, INSERT ke SQLite
Model Loading	Load model.json + shard files di browser	Sediakan file model statis, update saat retrain
Top-3 Display	Render Top-3 + confidence bar di Probe UI	—
Top-6 Internal	Simpan Top-4 s/d Top-6 di frontend (rahasia)	—
Top-6 Match Logic	—	Case-insensitive match di backend
Timer Count-Up	Tampilkan timer, kirim time_spent_ms	Simpan time_spent_ms ke log
Behavior Mapping	Spawn objek Solid/Danger sesuai mapping	Define lookup table (shared)

3.4 PEMBAGIAN TUGAS DAN ALUR Pengerjaan

Pengembangan proyek akhir ini dilakukan oleh dua orang dalam satu tim, yaitu penulis (Dias) dan Farchan Deano Muhammad (Can) sebagai rekan kerja. Pembagian tugas disesuaikan dengan bidang keahlian masing-masing anggota. Penulis bertanggung jawab pada aspek Backend, REST API, Model CNN MobileNet, Penyimpanan Log SQLite, K-Means Clustering, Admin Dashboard, dan Kontrak Data. Rekan (Can) bertanggung jawab pada aspek Frontend, UI/UX, Probe UI, Animasi Momo, Level Design, Mekanisme HITL Top-6 Check, dan Wireframe. Tabel 3.10 merinci pembagian tugas per komponen — tabel ini identik dengan yang ada pada Bab 3 Can untuk memastikan konsistensi kedua proposal.

Table 3.10: Pembagian Tugas Can dan Dias per Komponen Sistem

Komponen Sistem	Scope Can (Rekan)	Scope Dias (Penulis)
Login	UI Login Siswa (class_id + nomor_absen)	Backend endpoint POST /auth/login, JWT generation
Onboarding	Splash screen, Momo intro, Tutorial objek	—
Level Design	3 level (Trust Build, Ambiguity, Override)	—
Main Gameplay	Canvas, Kaplay.js loop, Stickman movement	—
Canvas Tools	Tombol Resize, Rotate, Eraser (UI)	—
Timer	Timer count-up display, time_spent_ms field	—
CNN Model	—	MobileNet V2 training, TF.js conversion
AI Inference	Load TF.js model di browser, tampilkan Top-3	—
Probe UI	Tampilan Top-3, tombol Accept/Correct/Override	—
Top-6 Check	Kirim POST /probe/override	Backend Top-6 Check, return auto-accept/redraw
Momo Animation	State machine, 5 state, text bubble	—
Behavior Mapping	Solid/Danger mapping (frontend)	Label mapping table (shared)
Backend API	—	Node.js + Express, REST endpoints
Database	—	SQLite, schema interaction_logs
K-Means Clustering	—	Python + scikit-learn, feature engineering
Admin Dashboard	—	Dashboard guru (decision distribution, cluster)
Superadmin UI	—	Dashboard superadmin (school/class/guru management)
Data Logging	Pack event, kirim POST /logs/event	Backend validasi, INSERT ke SQLite
Integrasi Can-Dias	Titik temu Probe UI + POST /logs/event	Titik temu Probe UI + POST /logs/event
Pengujian SUS	SUS ke siswa, behavioral log analysis	Akurasi model, dashboard testing

Titik temu (integration point) antara scope Dias dan Can berada di dua lokasi: (1) Probe UI — tempat output AI (Top-3 + confidence dari CNN model yang ditraining dan dikonversi penulis) bertemu input user (keputusan siswa dari frontend Can); (2) Endpoint POST /api/logs/event — tempat frontend Can mengirim behavioral log ke backend penulis. Kontrak data lengkap telah diuraikan pada Sub-bab 3.3.12.

Alur pengerjaan proyek dijalankan dalam empat tahap utama yang berurutan mengikuti Waterfall SDLC (lihat Sub-bab 3.2.2): (1) Research & Design — studi literatur, analisis kebutuhan, desain sistem backend, schema database; (2) Production — implementasi backend Dias dan frontend Can secara paralel; (3) Integration — integrasi Probe UI dan endpoint logging; (4) Testing & Documentation — pengujian black-box, akurasi model, SUS dashboard, dan penulisan laporan. Tahap Research & Design dan Production dijalankan paralel antara Can dan Dias; tahap Integration dan Testing memerlukan kolaborasi kedua anggota.

3.5 JADWAL PENELITIAN

Jadwal penelitian disusun untuk periode 12 bulan dengan pembagian waktu mengikuti tahapan Waterfall SDLC: studi literatur dan penyusunan proposal, analisis kebutuhan dan desain sistem, implementasi paralel Can-Dias, integrasi, pengujian, dan penulisan laporan akhir. Jadwal penelitian sinkron antara penulis (Dias) dan rekan (Can) — ditampilkan dalam satu tabel shared dengan kolom inisial pelaksana (C untuk Can, D untuk Dias, CD untuk Both). Jadwal penelitian ditunjukkan pada Tabel 3.11. Tabel ini identik dengan yang ada pada Bab 3 Can untuk memastikan konsistensi kedua proposal.

Table 3.11: Jadwal Penelitian Sinkron Can dan Dias — 17 Kegiatan $\times$ 12 Bulan

No	Kegiatan	Inisial	1	2	3	4	5	6	7	8	9	10	11	12
1	Studi Literatur & Pengumpulan Referensi	CD	X	X										
2	Penyusunan Proposal	CD		X	X	X								
3	Analisis Kebutuhan & Use Case (Fishbone 6M)	CD			X	X								
4	Desain Sistem Global (Waterfall)	CD				X	X							
5	Pengumpulan & Kurasi Dataset Quick Draw	D					X	X						
6	Pelatihan Model CNN MobileNet	D						X	X					
7	Konversi Model ke TensorFlow.js	D							X					
8	Pengembangan Frontend Kaplay.js + React	C					X	X	X	X				
9	Desain Maskot Momo (OPSI E Doodle Cube)	C						X	X					
10	Implementasi Level Design + HITL UI Top-6 Check	C							X	X	X			
11	Implementasi Backend REST API	D						X	X	X				
12	Implementasi Data Logging + SQLite	D								X	X			
13	Implementasi K-Means Clustering	D									X	X		
14	Implementasi Super-admin Dashboard	D									X	X		
15	Integrasi Can-Dias (Kontrak Data)	CD										X	X	
16	Pengujian SUS + Black-Box	CD											X	X
17	Penulisan Laporan Akhir	CD											X	X

Keterangan inisial: C = Can (Frontend, UI/UX, Maskot, HITL, Level Design); D = Dias (Backend, CNN, K-Means, API); CD = Both (kegiatan kolaboratif). Tanda X menandai bulan pelaksanaan kegiatan tersebut.

Fase studi literatur dan penyusunan proposal (Bulan 1–4) dilakukan

oleh Can dan Dias secara paralel. Fase analisis kebutuhan dan desain sistem (Bulan 3–5) meliputi pengumpulan referensi tambahan, analisis Fishbone 6M, dan desain sistem global mengikuti Waterfall SDLC. Fase implementasi paralel Can-Dias (Bulan 5–10) dijalankan secara bersamaan: Dias mengumpulkan dan kurasi dataset Quick Draw (116 kategori post-RSI-1), melatih model CNN MobileNet, konversi ke TF.js, mengimplementasi backend REST API, data logging SQLite, K-Means clustering, dan superadmin dashboard; Can mengembangkan frontend Kaplay.js + React, desain maskot Momo, dan implementasi Level Design + HITL Top-6 Check. Fase integrasi (Bulan 10–11) menyatukan Probe UI Can dengan endpoint logging Dias sesuai kontrak data. Fase pengujian (Bulan 11–12) meliputi black-box testing, akurasi model via confusion matrix, dan SUS untuk dashboard admin. Penulisan laporan akhir (Bulan 11–12) dilakukan secara bertahap dan paralel dengan pengujian.

DAFTAR PUSTAKA

BIBLIOGRAPHY

- [1] D. T. K. Ng, J. K. L. Leung, S. K. W. Chu, and M. S. Qiao, “Conceptualizing AI literacy: An exploratory review,” *Computers and Education: Artificial Intelligence*, vol. 2, p. 100041, 2021.
- [2] V. Casal-Otero et al., “AI literacy in K-12: A systematic literature review,” *International Journal of STEM Education*, vol. 10, p. 29, 2023.
- [3] H. Khosravi et al., “Explainable Artificial Intelligence in education,” *Computers and Education: Artificial Intelligence*, vol. 3, p. 100074, 2022.
- [4] E. Mosqueira-Rey, V. Alonso-Ríos, and B. Rubio-Ríos, “Human-in-the-loop machine learning: A state of the art,” *Artificial Intelligence Review*, vol. 56, no. 4, pp. 3005–3054, 2023.
- [5] B. Memarian and T. Doleck, “Human-in-the-loop in artificial intelligence in education: A review and entity-relationship (ER) analysis,” *Computers in Human Behavior: Artificial Humans*, vol. 2, p. 100053, 2024.
- [6] L. Xu et al., “Deep learning for free-hand sketch: A survey,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, no. 1, pp. 285–312, 2023.
- [7] G. Z. L. Goh, D. Ho, and Z. A. Abas, “Front-end deep learning web apps development and deployment: A review,” *Applied Intelligence*, vol. 53, pp. 15923–15945, 2023.
- [8] D. Smilkov et al., “TensorFlow.js: Machine learning for the web and beyond,” in *Proc. 2nd SysML Conf.*, 2019, pp. 1–10.

- [9] A. J. Karran, S. Demazure, and C. Hudelot, “Designing for confidence: The impact of visualizing artificial intelligence decisions,” *Frontiers in Neuroscience*, vol. 16, 2022.
- [10] P. Pansri et al., “Understanding student learning behavior through K-Means clustering,” *Education Sciences*, vol. 14, no. 12, p. 1291, 2024.
- [11] A. Alzahrani et al., “Identifying weekly student engagement patterns via K-Means clustering,” *Electronics*, vol. 14, no. 15, p. 3018, 2025.
- [12] M. Videnovik et al., “Game-based learning in computer science education: A scoping literature review,” *International Journal of STEM Education*, vol. 10, p. 54, 2023.
- [13] K. K. Chan, K. M. Wan, and R. B. King, “Performance over enjoyment? Effect of game-based learning on learning outcome and flow experience,” *Frontiers in Education*, vol. 6, p. 660376, 2021.
- [14] R. S. Pressman, *Software Engineering: A Practitioner’s Approach*, 8th ed. New York: McGraw-Hill, 2014.
- [15] I. Sommerville, *Software Engineering*, 10th ed. Pearson, 2015.
- [16] Sugiyono, *Metode Penelitian Kuantitatif, Kualitatif, dan R&D*. Bandung: Alfabeta, 2020.
- [17] J. W. Creswell, *Research Design: Qualitative, Quantitative, and Mixed Methods Approaches*, 4th ed. Sage Publications, 2014.
- [18] K. Ishikawa, *Guide to Quality Control*, 2nd ed. Tokyo: Asian Productivity Organization, 1986.
- [19] J. Brooke, “SUS: A ‘Quick and Dirty’ Usability Scale,” in *Usability Evaluation in Industry*, pp. 189–194, Taylor & Francis, 1996.

- [20] A. Bangor, P. T. Kortum, and J. T. Miller, “An empirical evaluation of the System Usability Scale,” *International Journal of Human-Computer Interaction*, vol. 24, no. 6, pp. 574–594, 2008.
- [21] M. Yin, J. Wortman Vaughan, and H. Wallach, “Understanding the effect of accuracy on trust in machine learning models,” in *Proc. 2019 CHI Conf. Human Factors in Computing Systems*, 2019, pp. 1–12.
- [22] C. Batanero and R. Álvarez-Arroyo, “Teaching and learning of probability,” *ZDM – Mathematics Education*, vol. 56, pp. 5–17, 2023.
- [23] Z. Zhan, Y. Tong, X. Lan, and B. Zhong, “A systematic literature review of game-based learning in artificial intelligence education,” *Interactive Learning Environments*, vol. 32, no. 4, pp. 1189–1212, 2024.
- [24] Q. V. Liao, D. Gruen, and S. Miller, “Questioning the AI: Informing design practices for explainable AI user experiences,” in *Proc. 2020 CHI Conf. Human Factors in Computing Systems*, 2020, pp. 1–15.
- [25] Y. Feldman-Maggor, M. Cukurova, C. Kent, R. Luckin, and M. Baur-Wolfson, “The impact of explainable AI on teachers’ trust and acceptance of AI EdTech recommendations,” *International Journal of Artificial Intelligence in Education*, vol. 35, no. 1, pp. 1–25, 2025.
- [26] V. T. Huynh, T. T. Nguyen, T. V. Nguyen, and M. T. Tran, “MobileNet-SA: Lightweight CNN with self attention for sketch classification,” in *Pacific-Rim Symposium on Image and Video Technology (PSIVT) 2023*, Springer, 2023, pp. 115–129.
- [27] L. Li, C. Zou, Y. Zheng, Q. Su, H. Fu, and C. L. Tai, “Sketch-R2CNN: An RNN-rasterization-CNN architecture for vector sketch recognition,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 9, pp. 4671–4685, 2020.

- [28] Google Creative Lab, “Quick, Draw! The Data,” Google, 2017. [Online]. Available: <https://quickdraw.withgoogle.com/data>
- [29] F. Liu, M. Lu, and W. Zhang, “Comparative analysis of deep learning-based models in sketch recognition,” in Proc. ICAIC 2024, Atlantis Press, 2024.